Ejercicio 04 · Unidad 02 (U02.LAB07)

Clasificador visual con CNN y Model Card sobre Fashion-MNIST

Estudiante	Edwing Perez
Repositorio	https://github.com/edvvdev/unidad02-02
Curso	INF-8239 Ciencia de Datos II · Unidad 02
Laboratorio	U02.LAB07 · Visión computacional: CNN reproducible con Fashion-MNIST
Fecha del informe	2026-11-06

Entrega académica: auditoría del dataset y partición reproducible, baseline denso frente a CNN con la misma partición y semilla, métricas globales y por clase, matriz de confusión, análisis de errores por clase, comparación de costo y tamaño, decisión técnica, notebook ejecutado, pruebas y Model Card.

Reproducibilidad. Todo el contenido de este informe se genera con los comandos del README: `uv sync --extra cpu` seguido de `bash scripts/run_all.sh`, que deja los artefactos en `reports/` y regenera este PDF. Ninguna cifra está escrita a mano: todas se leen de `reports/cv_metrics.json`, `reports/cv_per_class.csv`, `reports/cv_errors_by_class.csv`, `reports/budget_study.json` y `reports/dataset_audit.json`.

Comprobaciones de la entrega

Comprobación	Resultado
Pruebas automáticas	uv run pytest -q : todas en verde
Linter	uv run ruff check . : sin incidencias
Notebook	notebooks/01_ejercicio04_cnn_model_card.ipynb ejecutado, 0 celdas con error
Clon limpio	bash scripts/run_all.sh ejecutado desde un clon de GitHub sin errores

1. Identificación del dataset y partición

Dataset. Fashion-MNIST, benchmark público de moda en escala de grises. Imágenes de 28x28 píxeles, canal único, 10 clases. Procedencia: descarga automática de `tf.keras.datasets.fashion_mnist` (ficha de Keras, licencia MIT). El bloque oficial de entrenamiento tiene 60000 imágenes y el de prueba 10000.

Preprocesamiento. Conversión a float32, división por 255 (rango [0, 1]) y añadido del canal, de modo que la forma de entrada es (N, 28, 28, 1). Rango comprobado en la auditoría: [0, 1].

Partición reproducible. Fija y determinista: las últimas 6000 imágenes del bloque de 60.000 son validación y las 54000 restantes son entrenamiento. Las 10000 imágenes del bloque oficial de prueba no se usan nunca durante el entrenamiento. Semilla **42** en Python, NumPy y TensorFlow.

Partición	Imágenes	Forma	Rango	Desbalance max/min	Reparto min-max por clase
Entrenamiento	54000	(28, 28, 1)	[0, 1]	1.0145	5367 - 5445
Validación	6000	(28, 28, 1)	[0, 1]	1.1405	555 - 633
Prueba	10000	(28, 28, 1)	[0, 1]	1.0000	1000 - 1000

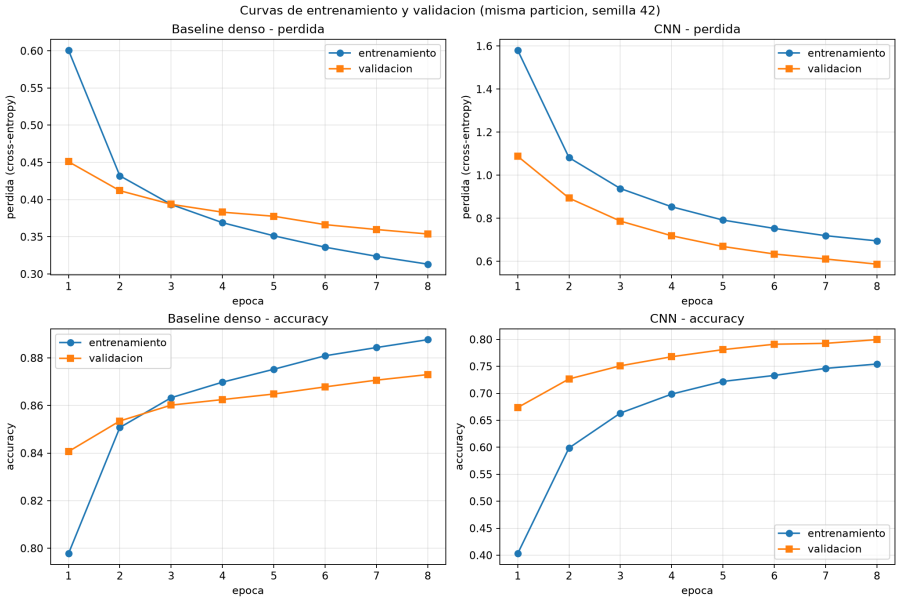
El reparto por clase es casi uniforme (cada clase representa cerca del 10 % en las tres particiones), de modo que el promedio global no está inflado por clases mayoritarias.

2. Resultados: baseline denso frente a CNN

Los dos modelos se entrenan con la **misma partición** (54.000 / 6.000 / 10.000) y la **misma semilla (42)**, con optimizador Adam, batch 128 y EarlyStopping (patience 2, restore_best_weights=True), con un máximo de 8 épocas. El tiempo de inferencia es la **mediana de tres mediciones** sobre las 10.000 imágenes de prueba.

Métrica	Baseline denso	CNN	Diferencia (CNN - denso)
F1 macro	0.8647	0.7892	-0.0755
Accuracy	0.8663	0.7930	-0.0733
Parámetros entrenables	50890	19466	-31424
Tamaño del modelo (.keras)	619.12 KB	262.17 KB	-356.95 KB
Tiempo de entrenamiento	12.2 s	68.9 s	+56.7 s
Inferencia (mediana de 3)	0.0512 ms/img	0.0823 ms/img	+0.0311 ms/img
Épocas ejecutadas	8	8	-

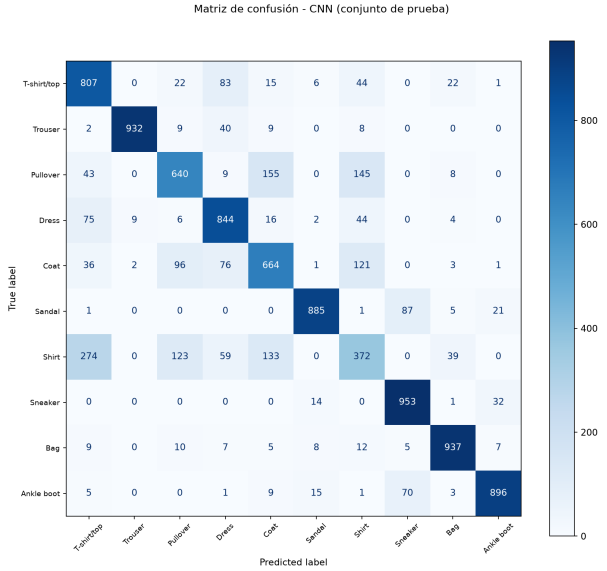
Curvas. El baseline denso converge con suavidad: la pérdida de entrenamiento baja de 0.6009 a 0.3132 y la de validación de 0.4510 a 0.3538; ambas perdidas descienden de forma sostenida (entrenamiento 0.6009 -> 0.3132 y validacion 0.4510 -> 0.3538) y no hay sobreajuste. La CNN parte de una pérdida mucho más alta (1.5808) y en la última época sigue en 0.6953 con una pérdida de validación de 0.5872 y una accuracy de validación de 0.7995: la perdida de validacion sigue descendiendo en la ultima epoca (0.5872) y la curva no se ha estabilizado, con una perdida de entrenamiento de 0.6953: es un patron de subajuste con este presupuesto de entrenamiento. El diagnóstico es el mismo que aplica el notebook (celda 2.1) y el que documenta la Model Card.



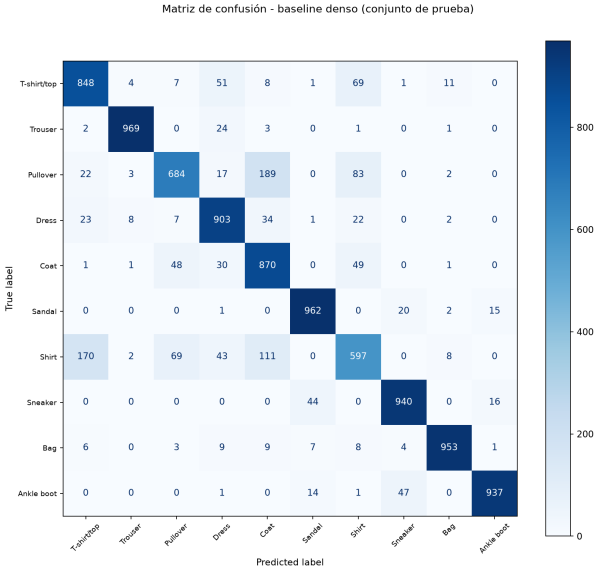
Curvas de pérdida y accuracy de entrenamiento y validación de los dos modelos, con la misma partición y la misma semilla. La curva de validación de la CNN sigue bajando en la última época: no se ha estabilizado.

3. Evidencia visual: matrices de confusión y ejemplos

Las dos matrices se calculan sobre las mismas 10.000 imágenes de prueba (filas = clase real, columnas = clase predicha). La diagonal concentra los aciertos; la matriz del baseline denso es la evidencia que sostiene la decisión técnica: el denso pierde muchas menos prendas de torso que la CNN.



Matriz de confusión de la CNN



Matriz de confusión del baseline denso



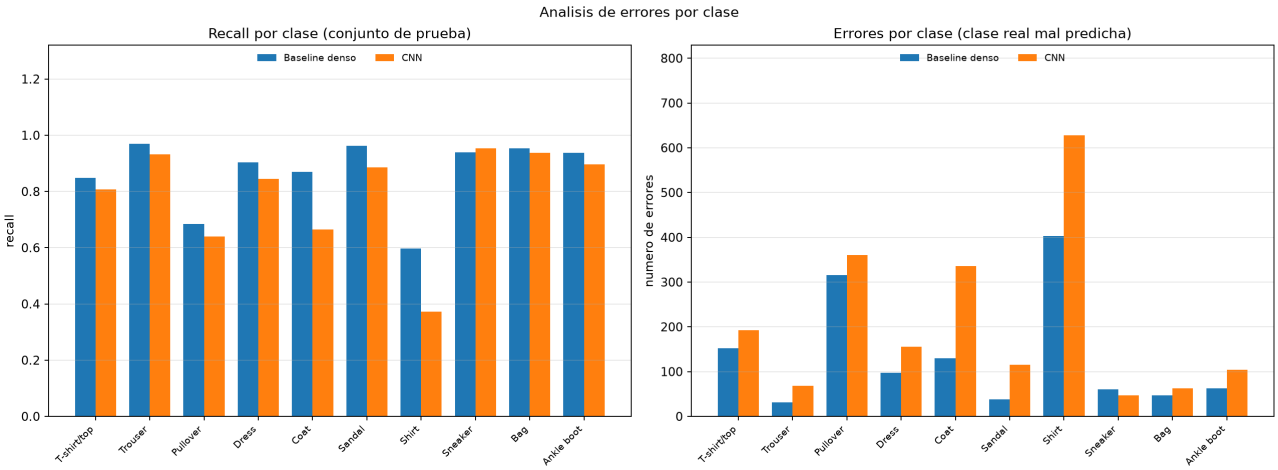
Dieciséis ejemplos mal clasificados por la CNN elegidos al azar con semilla fija (42), con la clase real y la predicción. Los pares visualmente semejantes (Coat/Pullover, Shirt/T-shirt-top, Sandal/Sneaker) confirman que se trata de ambigüedad de la imagen.

4. Análisis de errores por clase

El promedio global puede esconder una debilidad. La tabla siguiente procede de `reports/cv_errors_by_class.csv`: para cada clase, cuántos ejemplos reales se pierden y cuántos falsos positivos genera.

Clase	Recall denso	Recall CNN	F1 denso	F1 CNN	Errores denso	Errores CNN	Falsos pos. CNN
T-shirt/top	0.848	0.807	0.8185	0.7167	152	193	445
Trouser	0.969	0.932	0.9753	0.9593	31	68	11
Pullover	0.684	0.64	0.7525	0.6716	316	360	266
Dress	0.903	0.844	0.8687	0.7966	97	156	275
Coat	0.87	0.664	0.7824	0.662	130	336	342
Sandal	0.962	0.885	0.9483	0.9166	38	115	46
Shirt	0.597	0.372	0.6525	0.4256	403	628	376
Sneaker	0.94	0.953	0.9344	0.9012	60	47	162
Bag	0.953	0.937	0.9626	0.9268	47	63	85
Ankle boot	0.937	0.896	0.9518	0.9152	63	104	62

Clases que se pierden. Con el presupuesto del manual las tres clases más afectadas son **Shirt** (recall 0.372, 628 errores), **Pullover** (recall 0.640, 360 errores), **Coat** (recall 0.664, 336 errores) para la CNN y **Shirt** (recall 0.597), **Pullover** (recall 0.684), **T-shirt/top** (recall 0.848) para el baseline denso. El motivo es visual: las prendas de torso (T-shirt/top, Pullover, Coat, Shirt) se distinguen por un cuello y una manga de pocos píxeles, y el calzado (Sandal, Sneaker, Ankle boot) por la suela y el tobillo. Son ambigüedades reales de la imagen de 28x28, no fallos de etiqueta.



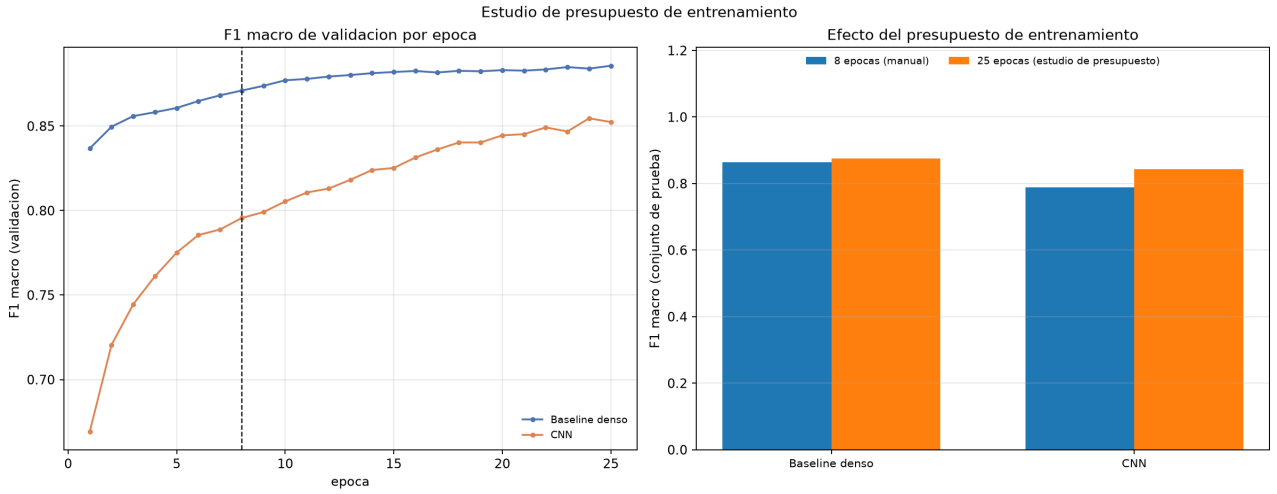
Recall por clase y número de errores por clase de los dos modelos sobre el conjunto de prueba. La leyenda se mantiene fuera del área de las barras para no taparlas.

5. Estudio complementario de presupuesto

Qué pregunta responde. Las curvas dejan abierta la pregunta de si la diferencia entre los dos modelos es una limitación de la arquitectura o del número de épocas. El proyecto repite la comparación con **25 épocas**, misma partición y misma semilla, y calcula las curvas por época sobre el conjunto de validación, nunca sobre la prueba.

Modelo	F1 macro (8 ep.)	F1 macro (25 ep.)	Entrenamiento	Parámetros	Tamaño (.keras)
Baseline denso	0.8647	0.8761	32.0 s	50890	619.11 KB
CNN	0.7892	0.8439	215.3 s	19466	262.16 KB

Con el presupuesto ampliado la CNN mejora (F1 macro 0.8439) y se acerca al baseline denso (0.8761), pero no lo supera. El resultado es **compatible con una mejora de la arquitectura de la CNN al Trainar con más cómputo**; con una sola semilla y sin intervalos de confianza **no permite separar de forma concluyente** el efecto del presupuesto del efecto de la arquitectura. El experimento es **complementario**: la comparación oficial del laboratorio sigue siendo la de 8 épocas y su resultado se reporta sin modificar.



Izquierda: F1 macro de validación por época de los dos modelos, con la línea que marca el presupuesto del manual. Derecha: efecto del presupuesto de entrenamiento sobre el F1 macro del conjunto de prueba. La leyenda se mantiene fuera del área de las barras.

6. Decisión técnica y alcance

```
Decision tecnica (calculada sobre las metricas de esta ejecucion)
------------------------------------------------------------
Modelo entregado: Baseline denso
Presupuesto del manual (8 epocas):
F1 macro denso = 0.8647 | F1 macro CNN = 0.7892 (-0.0755)
Entrenamiento denso = 12.2 s | CNN = 68.9 s (5.6x)
Parametros denso = 50890 | CNN = 19466
Tamano denso = 619.12 KB | CNN = 262.17 KB
Inferencia mediana denso = 0.0512 ms/img | CNN = 0.0823 ms/img (1.6x)
Presupuesto ampliado (25 epocas, experimento complementario):
F1 macro denso = 0.8761 | F1 macro CNN = 0.8439 (-0.0322)
```

```
Justificacion: Con 8 epocas el baseline denso alcanza un F1 macro de 0.8647 frente a 0.7892 de la CNN, y ademas
entrena 5.6 veces mas rapido y infiere 1.6 veces mas rapido. La CNN no aporta mejora predictiva con este
presupuesto, de modo que segun el principio Green AI del manual (mas accuracy no es automaticamente mejor, y hay
que justificar el coste) no se justifica su coste de entrenamiento. Con 25 epocas la CNN sube a 0.8439 y el denso
a 0.8761: el resultado es compatible con una mejora de la arquitectura de la CNN al entrenar con mas computo, pero
con una sola semilla y sin intervalos de confianza no permite separar de forma concluyente el efecto del
presupuesto del efecto de la arquitectura.
Alternativa documentada: La CNN se conserva como alternativa documentada: usa 19466 parametros frente a 50890 del
denso y ocupa 262.17 KB frente a 619.12 KB, es decir, la unica dimension en la que gana es la huella (memoria y
tamano desplegado). Es el modelo que habria que elegir si la restriccion dominante fuera el tamano del artefacto o
la memoria del dispositivo, no el tiempo de CPU.
Limitacion del benchmark: Fashion-MNIST es didactico; el resultado no se extrapola
a imagenes medicas, OCR ni vigilancia.
Limitacion del entorno: la ejecucion fue en CPU (sin GPU detectada), por lo que los
tiempos de entrenamiento e inferencia son validos para esta maquina y no para un equipo
con GPU.
```

Lectura Green AI. El coste se compara en cinco dimensiones: F1 macro, parámetros, tamaño en disco, tiempo de entrenamiento y tiempo de inferencia. Con el presupuesto que fija el manual (8 épocas) el baseline denso gana en F1 macro (0.8647 frente a 0.7892), tiempo de entrenamiento (12.2 s frente a 68.9 s), inferencia mediana (0.0512 frente a 0.0823 ms por imagen); la CNN gana únicamente en parámetros (19466 frente a 50890), tamaño en disco (262.17 frente a 619.12 KB). La CNN es más compacta pero más lenta y, en este dataset y con este presupuesto, no aporta ninguna mejora predictiva: una mejora que no existe no justifica el coste adicional. Queda documentada como la opción preferente cuando la restricción dominante sea la memoria o el tamaño del artefacto desplegado.

Alcance y límites. Fashion-MNIST es un benchmark didáctico de siluetas de moda en 28x28: un buen resultado **no** demuestra preparación para imágenes médicas, OCR, vigilancia ni ningún otro dominio, y el modelo no debe usarse sin supervisión humana en decisiones que afecten a personas. **Limitación del entorno de ejecución.** La ejecución se hizo en CPU (20 núcleos, GPU detectada: ninguna), con TensorFlow 2.21.0 sobre Python 3.12.15: los tiempos de entrenamiento e inferencia son válidos para esta máquina y no deben generalizarse a un equipo con GPU.

7. Uso de inteligencia artificial y entrega

Herramienta. Kilo, agente de programación asistido por IA ejecutado en la terminal del estudiante (modelo MiniMax-M3). **Finalidad:** estructura del proyecto, código de los scripts y del módulo de la biblioteca, pruebas, redacción de la documentación, ejecución y depuración. **La IA no generó datos ni resultados:** todas las cifras proceden de ejecuciones reales del repositorio y están respaldadas por `reports/*.json` y `reports/*.csv`. **Prompts relevantes:** el encargo que exige que toda cifra salga de los artefactos generados, que el notebook se ejecute de principio a fin sin errores, que la inferencia se mida varias veces con mediana, que la comparación sea justa con la misma partición y semilla, y que el PDF y el README no puedan contradecir la evidencia. **Verificaciones del estudiante:** partición y semilla comprobadas contra la ejecución del script, matriz de confusión contrastada con los soportes por clase, parámetros y tamaño verificados sobre los archivos .keras guardados, curvas leídas época a época, pruebas y lint en verde antes de publicar y clon limpio ejecutado desde GitHub. **Correcciones realizadas:** se detectó y corrigió la partición relativa del modelo cuando la carpeta de destino estaba fuera del proyecto, se ajustó el diseño de las figuras para que los títulos no se solaparan y se detectó que la CNN queda en subajuste con el presupuesto del manual, lo que motivó el estudio complementario de presupuesto. El detalle completo está en `AI_USE_DECLARATION.md`.

Entregable técnico. Notebook ejecutado, `src/inf8239_u02_cv/`, `scripts/`, `tests/`, `reports/`, `models/best_dense.keras`, `MODEL_CARD.md`, `AI_USE_DECLARATION.md`, `CAMBIOS_AL_BASE.md` y `README.md`.

Repositorio: https://github.com/edvvdev/unidad02-02